UNIVERSIDADE FEDERAL DE ITAJUBÁ

XMCO09 - CIÊNCIA DE REDES

ANÁLISE DA EVASÃO ACADÊMICA POR MEIO DE REDES DE SIMILARIDADE DE ATRIBUTOS

2022012137 - Bianca Salvador
2022004289 - Filipe Cruz Siqueira
2022002097 - Laura Raimundi Dias Jesus

XMCO09 - CIÊNCIA DE REDES

Prof. Rafael Frinhani

INSTITUTO DE MATEMÁTICA E COMPUTAÇÃO
UNIFEI - Itajubá

2026

UNIVERSIDADE FEDERAL DE ITAJUBÁ
INSTITUTO DE MATEMÁTICA E COMPUTAÇÃO
CIÊNCIA DA COMPUTAÇÃO E SISTEMAS DE INFORMAÇÃO
XMCO09 - CIÊNCIA DE REDES

Análise da evasão acadêmica por meio de redes de similaridade de atributos

Resumo: A evasão no ensino superior gera perdas para estudantes, instituições e para a sociedade, e costuma ser estudada com modelos tabulares que tratam cada estudante de forma isolada. Este trabalho investiga se a evasão se organiza em grupos de estudantes com perfis semelhantes. Para isso, a base pública de 4.424 estudantes de um instituto politécnico português foi transformada em uma rede de similaridade, na qual os nós são estudantes e as arestas ligam pares cuja similaridade de 30 atributos demográficos, socioeconômicos e acadêmicos supera um limiar. Seguindo um método de redes de similaridade já aplicado à assistência estudantil, foram comparados três modelos de similaridade e três algoritmos de detecção de comunidades em limiares de 0% a 90%. A rede escolhida (modelo multirelacional, limiar de 35%) é conexa, esparsa e possui quatro comunidades com modularidade 0,58. A situação acadêmica final, que não participa da construção da rede, distribui-se de forma não aleatória: uma comunidade concentra 59% de evadidos, contra 32% na base, e é marcada por maior idade, inadimplência e turno noturno. A rede exibe propriedades de mundo pequeno, é melhor aproximada pelo modelo de Watts–Strogatz, mas apresenta assortatividade de grau que nenhum modelo clássico reproduz. Ela é robusta a remoções aleatórias e se fragmenta sob ataques por betweenness a partir de 60% dos nós removidos. Os resultados indicam perfis de risco identificáveis pela estrutura da rede, úteis para priorizar ações de retenção.

Palavras-chave: Ciência de Redes; CRISP-NET; Evasão acadêmica; Redes de similaridade; Detecção de comunidades; Robustez.

1 Introdução

1.1 Contexto e problema de pesquisa

A evasão no ensino superior é o abandono do curso antes da sua conclusão. No Brasil, o acompanhamento dos ingressantes de 2010 mostrou que 49% deles haviam desistido do curso de ingresso até 2014 (INEP, 2016). O fenômeno tem causas múltiplas: modelos clássicos o explicam pela integração acadêmica e social do estudante (Tinto, 1975) e, no caso de estudantes não tradicionais (mais velhos, que trabalham ou com obrigações financeiras), por fatores externos como renda e conflito entre trabalho e estudo (Bean & Metzner, 1985).

Este trabalho delimita o problema à *Predicting Student Dropout and Academic Success* (Realinho et al., 2022), com 4.424 estudantes de 17 cursos de graduação do Instituto Politécnico de Portalegre (Portugal), descritos por atributos demográficos, socioeconômicos e acadêmicos e pela situação final (*Dropout*, *Enrolled* ou *Graduate*). O problema investigado é: **estudantes com perfis semelhantes formam grupos, e a evasão se concentra em algum desses grupos?** Como a base é tabular e não registra interações entre estudantes, a rede precisa ser derivada dos próprios atributos. Para isso adota-se a abordagem de redes de similaridade de Porto & Frinhani (2021) e Porto (2022), desenvolvida para agrupar solicitantes de auxílio estudantil e aqui aplicada, pela primeira vez, ao problema da evasão.

Entidades e relações. Os **nós** são os estudantes. As **arestas** representam similaridade de perfil: dois estudantes são ligados quando seus atributos demográficos, socioeconômicos e acadêmicos são suficientemente semelhantes. A relação é simétrica (rede não direcionada) e graduada (peso igual à similaridade). Como não há interação observada entre os estudantes, a rede é uma **aproximação por perfis**, e o *Target* é usado apenas para interpretar a estrutura, nunca para construí-la.

1.2 Relevância e motivação

A evasão representa perda de investimento público e privado, ociosidade de vagas e formação interrompida, com impacto sobre o estudante, sua família e a instituição (Tontini & Walter, 2014). A literatura de mineração de dados educacionais já prevê a evasão com boa acurácia, mas raramente transforma essas previsões em instrumentos de gestão (Colpo et al., 2024). Identificar *grupos* de estudantes com perfis de risco, e não apenas classificar indivíduos, aproxima a análise da forma como as ações institucionais são planejadas: por programas voltados a públicos-alvo.

1.3 Aplicação e tomada de decisão

Os resultados apoiam coordenações de curso e setores de assistência estudantil em três decisões: (*i*) **priorizar** as comunidades com fração de evadidos acima da média para tutoria, nivelamento ou apoio financeiro; (*ii*) **caracterizar** cada comunidade pelos atributos que a diferencia, orientando o tipo de ação (financeira, pedagógica ou de horário); e (*iii*) **identificar perfis-ponte**, estudantes que conectam comunidades distintas e cuja ausência fragmentaria a rede de perfis.

1.4 Questões de pesquisa e hipóteses

- **RQ1:** A rede de similaridade apresenta estrutura de comunidades significativa, e os estudantes evadidos concentram-se em comunidades específicas?

- **RQ2:** Qual modelo de referência (Erdős–Rényi, Watts–Strogatz ou Barabási–Albert) melhor reproduz a topologia da rede?
- **RQ3:** A rede é mais vulnerável a falhas aleatórias ou a ataques direcionados a nós de alta centralidade?

H1 (comunidades e homofilia): estudantes semelhantes formam comunidades e a evasão não se distribui ao acaso entre elas. É confirmada se: (a) a modularidade da rede supera a de redes nulas com a mesma sequência de graus (30 réplicas, $z > 2$); (b) a assortatividade do *Target* for positiva em teste de permutação (1.000 permutações, $p < 0{,}05$); e (c) alguma comunidade tiver fração de evadidos $\geq 1{,}5\times$ a fração global. **H2 (mundo pequeno):** a rede tem agrupamento muito acima de uma rede aleatória com caminhos médios semelhantes; é confirmada se o coeficiente σ de Humphries & Gurney (2008) for maior que 1. **H3 (vulnerabilidade a ataques):** a rede fragmenta-se com menos remoções sob ataques direcionados do que sob falhas aleatórias, isto é, $f_c^{\text{ataque}} < f_c^{\text{aleatória}}$.

1.5 Objetivos

Objetivo geral: caracterizar a estrutura de uma rede de similaridade de estudantes e sua relação com a evasão, para apoiar a priorização de ações de retenção.
Objetivos específicos:
OE1: construir a rede segundo os modelos de similaridade de Porto (2022) e caracterizá-la por métricas globais e de centralidade;
OE2: detectar comunidades e medir sua associação com o *Target*;
OE3: comparar a rede com os modelos ER, WS e BA de mesmo N e L;
OE4: avaliar a robustez da rede a falhas aleatórias e ataques direcionados.

1.6 Tipo de análise e critérios de sucesso

A análise é **descritiva** (métricas globais, distribuição de graus e centralidades), **exploratória** (detecção de comunidades por Fast Greedy, Louvain e Walktrap) e de **simulação** (modelos de referência e remoção de nós). Os critérios de sucesso são os testes das hipóteses (Subseção 1.4) e, para a RQ2, erro relativo de até ±15% entre o modelo mais aderente e a rede empírica no agrupamento médio e no caminho médio. A Tabela 1 resume o alinhamento entre objetivos, questões, hipóteses e métodos.

Tabela 1: Relação entre objetivos, questões, hipóteses e métodos.

Objetivo	RQ / H	Método (seção)	Evidência esperada
OE1 + OE2	RQ1 / H1	3.3, 3.5	Comunidades com concentração de evadidos
OE3	RQ2 / H2	3.6	Modelo mais aderente e propriedades não reproduzidas
OE4	RQ3 / H3	3.7	Limiar crítico menor sob ataque

Contribuições e organização. As contribuições são: (*i*) a aplicação da abordagem de redes de similaridade de Porto (2022) a uma base de evasão; (*ii*) a verificação estatística, contra modelos nulos, de que a evasão se concentra em comunidades; e (*iii*) a análise de robustez da rede de perfis. A Seção 2 apresenta o referencial teórico, a Seção 3 descreve a metodologia e os resultados de cada fase da CRISP-NET e a Seção 4 traz as considerações parciais. Código, dados derivados e figuras estão em https://github.com/Flip-Cruz/Dropout-Analysis-XMCO09/tree/arquivos-parcial-v2.

2 Referencial Teórico

2.1 Fundamentos de Ciência de Redes

Uma rede é um grafo $G = (V, E)$ com $N = |V|$ nós e $L = |E|$ arestas (Barabási, 2016). As métricas usadas neste trabalho são: densidade $\rho = 2L/[N(N-1)]$; grau k_i e grau médio $\langle k \rangle = 2L/N$; distribuição de graus $P(k)$; heterogeneidade $\kappa = \langle k^2 \rangle / \langle k \rangle$; maior componente conexo (GCC); caminho médio $\langle d \rangle$ e diâmetro; coeficiente de agrupamento local, médio e global (transitividade); assortatividade de grau, que mede se nós de grau alto se ligam entre si (Newman, 2002); e centralidades de grau, intermediação (*betweenness*), proximidade (*closeness*) e autovetor.

2.2 Modelos clássicos de redes

O modelo de **Erdős–Rényi** (ER) liga pares de nós ao acaso, gerando $P(k)$ de Poisson, caminhos curtos e agrupamento igual à densidade (Erdős & Rényi, 1959). O modelo de **Watts–Strogatz** (WS) parte de um anel regular e religa arestas com probabilidade p; para p intermediário, combina agrupamento alto e caminhos curtos, caracterizando redes de **mundo pequeno** (Watts & Strogatz, 1998), que podem ser quantificadas pelo coeficiente $\sigma = (C/C_{ER})/(\langle d \rangle / \langle d \rangle_{ER})$, com $\sigma > 1$ indicando mundo pequeno (Humphries & Gurney, 2008). O modelo de **Barabási–Albert** (BA) cresce por ligação preferencial e gera $P(k)$ em lei de potência, com *hubs* (Barabási & Albert, 1999). Nenhum dos três gera, por construção, comunidades ou assortatividade de grau. Redes construídas por proximidade em um espaço de atributos se assemelham a grafos geométricos aleatórios, em que a transitividade da proximidade produz agrupamento elevado (Dall & Christensen, 2002).

2.3 Comunidades e modularidade

Comunidades são grupos de nós mais densamente ligados entre si do que com o restante da rede. A modularidade Q compara a fração de arestas internas às comunidades com a esperada em uma rede aleatória de mesma sequência de graus (Newman & Girvan, 2004; Newman, 2006). Três algoritmos são usados neste trabalho: **Fast Greedy**, aglomerativo e guloso na maximização de Q (Clauset et al., 2004); **Multilevel** (Louvain), que otimiza Q localmente e agrega comunidades em níveis (Blondel et al., 2008); e **Walktrap**, baseado em passeios aleatórios curtos que tendem a permanecer na mesma comunidade (Pons & Latapy, 2006).

2.4 Robustez e percolação

A robustez mede como a remoção de nós afeta a conectividade, em geral pela fração S de nós no GCC. Redes com *hubs* toleram falhas aleatórias, mas são vulneráveis a ataques direcionados a nós centrais (Albert et al., 2000). O critério de Molloy & Reed (1995) estabelece que existe componente gigante se $\kappa > 2$, e a teoria da percolação prevê o limiar crítico de falhas aleatórias

$f_c = 1 - 1/(\kappa - 1)$ para redes sem correlações de grau (Barabási, 2016).

2.5 Justificativa da abordagem em redes

Modelos tabulares classificam cada estudante isoladamente. A representação em rede acrescenta três elementos: (*i*) a detecção de comunidades encontra grupos de perfis **sem fixar previamente o número de grupos**, diferentemente de algoritmos como o *k*-means (Porto, 2022); (*ii*) a rede permite testar **homofilia**, isto é, se estudantes com o mesmo desfecho são vizinhos com frequência maior que a esperada ao acaso, contra modelos nulos; e (*iii*) a estrutura revela **perfis-ponte** entre grupos e a dependência da coesão da população em relação a eles, por meio de simulações de robustez. Esses resultados não são obtidos diretamente da tabela de atributos.

2.6 Trabalhos relacionados e lacuna

A Tabela 2 compara os trabalhos mais próximos. Realinho et al. (2022) disponibilizam a base e aplicam classificadores; Kim et al. (2023) e Jiménez-Macías et al. (2023) mostram, com aprendizado de máquina, que atributos acadêmicos e socioeconômicos são os mais importantes para prever a evasão; Colpo et al. (2024) revisam a área e apontam o predomínio de abordagens tabulares. Almeida et al. (2025) convertem dados tabulares em grafos para redes neurais e mostram que o resultado depende fortemente da regra de construção do grafo. Porto & Frinhani (2021) e Porto (2022) propõem três modelos de rede de similaridade e critérios explícitos de escolha do limiar e da partição, aplicados a solicitantes de auxílio estudantil da UNIFEI.

Tabela 2: Trabalhos relacionados.

Referência	Rede (nós / arestas)	Métodos	Limitação
Realinho et al. (2022)	Sem rede (tabular)	Classificadores	Estudantes independentes
Kim et al. (2023)	Sem rede (tabular)	RF, SVM, KNN, remoção de grupos	Sem estrutura relacional
Jiménez-Macías et al. (2023)	Sem rede (tabular)	Importância de atributos	Sem estrutura relacional
Almeida et al. (2025)	Estudantes / agrupamento	GCN, GraphSAGE	Foco preditivo; grafo sem análise estrutural
Porto (2022)	Solicitantes de auxílio / similaridade $\geq W$	3 modelos de similaridade, 3 algoritmos de comunidades	Sem modelos nulos, robustez ou evasão

Lacuna. Os estudos de evasão tratam os estudantes como observações independentes, e os que usam grafos o fazem com fins preditivos, sem analisar a estrutura da rede. Por outro lado, o método de Porto (2022) não foi aplicado à evasão nem confrontado com modelos nulos, modelos de referência ou testes de robustez. Este trabalho ocupa essa lacuna.

3 Metodologia

3.1 Visão geral do método

O trabalho segue a metodologia CRISP-NET (Figura 1). A Fase 1 (Seção 1) definiu o problema e os objetivos. A Fase 2 descreve e verifica os dados (Subseções 3.2 e 3.4). A Fase 3 constrói as redes de similaridade e seleciona a rede *baseline* (Subseções 3.3 e 3.5). A Fase 4 compara a *baseline* com modelos de referência (Subseção 3.6) e avalia sua robustez (Subseção 3.7). Toda a análise foi feita em Python com a biblioteca igraph (Csárdi & Nepusz, 2006), com semente aleatória fixa (`SEED = 42`); os dois *notebooks*, os dados derivados e as figuras estão no repositório do projeto[1], e cada célula indica o item de avaliação que atende.

Fase 1	Fase 2	Fase 3	Fase 4
Problema, RQs e hipóteses	Fonte, EDA, qualidade e seleção de atributos	M1, M2, M3 $\times$ W (0–90%) $\times$ 3 algoritmos $\rightarrow$ *baseline*	Métricas, H1, ER/WS/BA (H2) e robustez (H3)

Figura 1: Fluxo do trabalho segundo a CRISP-NET.

3.2 Coleta e raiz dos dados

Fonte e aquisição. A base foi obtida no *UCI Machine Learning Repository* (`https://doi.org/10.24432/C5MC89`, licença CC BY 4.0), em um único arquivo `data.csv`. Foi compilada por Realinho et al. (2022) a partir de bases institucionais desconexas do Instituto Politécnico de Portalegre (sistema acadêmico, sistema de candidatura e indicadores macroeconômicos do Instituto Nacional de Estatística de Portugal), com a finalidade original de treinar modelos de predição precoce de evasão. Trata-se de uma base pública, real, estática e tabular, sem relações observadas entre estudantes.

Período, cobertura e representatividade. A base cobre estudantes matriculados entre os anos letivos de 2008/2009 e 2018/2019, em 17 cursos de graduação (agronomia, design, educação, enfermagem, jornalismo, gestão, serviço social, tecnologias, entre outros). São 4.424 estudantes e 36 atributos, além do *Target*: *Graduate* 2.209 (49,9%), *Dropout* 1.421 (32,1%) e *Enrolled* 794 (17,9%). A população é a totalidade dos ingressantes dos cursos no período, não uma amostra.

Inspeção estrutural. A base é um único arquivo CSV com 4.424 linhas (um estudante por linha, unidade de observação) e 37 colunas, separadas por ponto e vírgula. Foram encontrados dois erros de codificação, tratados na leitura: marca de ordem de *bytes* (BOM) no início do arquivo e um caractere de tabulação no nome da coluna de turno. Todos os atributos categóricos já vêm codificados como inteiros, e as notas como números reais.

Limitações e vieses. (*i*) Uma única instituição de um único país, o que limita a generalização. (*ii*) A classe *Enrolled* é um desfecho em aberto (censurado): parte desses estudantes ainda pode evadir. (*iii*) Os atributos de desempenho no 1º e 2º semestres antecipam o desfecho; isso não compromete uma análise descritiva, mas impede tratar o resultado como detecção precoce. (*iv*) Os três atributos macroeconômicos são idênticos para toda a coorte de um ano e criariam similaridade artificial. (*v*) Cerca de 97% dos estudantes têm a mesma nacionalidade.

3.3 Construção do grafo

Nós e arestas. Cada nó é um estudante ($N = 4.424$). Existe aresta entre os estudantes x e y se a similaridade R_{xy} entre seus vetores de atributos for maior ou igual a um limiar W, como em Porto (2022). A rede é unipartida, **não direcionada** (a similaridade é simétrica), **ponderada** (peso $R_{xy} \in [0, 1]$,

[1] `https://github.com/Flip-Cruz/Dropout-Analysis-XMCO09/tree/arquivos-parcial-v2`

adimensional) e **estática**: os atributos são fixos e registrados no ingresso e nos dois primeiros semestres, não havendo dimensão temporal. Não há interação real entre os estudantes; a rede é uma **aproximação por perfis**, e uma aresta significa "perfis semelhantes", não "contato".

Modelos de similaridade. Foram avaliados os três modelos de Porto (2022), sobre $n = 30$ atributos (Subseção 3.4):

- **M1 – Contagem Direta:** $R_{xy} = \frac{1}{n}\sum_{a=1}^{n}[x_a = y_a]$, a fração de atributos iguais.
- **M2 – Multirelacional** (adaptado de Menezes, 2012): os atributos são agrupados em conjuntos G, e $R_{xy} = \sum_G w_G \frac{\sum_{a\in G}[x_a = y_a]}{P_{G,x} + P_{G,y}}$, em que $P_{G,x}$ é o número de coincidências de x com todos os demais estudantes nos atributos de G, o que relativiza a força de cada relação. O resultado é normalizado por $\max R$.
- **M3 – Medida Ordinal** (Han et al., 2012): cada atributo é normalizado por $z = (r-1)/(A-1)$, com r a classe e A o número de classes, e $R_{xy} = 1 - \sqrt{\frac{1}{n}\sum_a (z_{x,a} - z_{y,a})^2}$. Como Porto (2022) usou apenas atributos ordenáveis, adaptou-se o modelo aos atributos nominais (curso, ocupação etc.), para os quais a diferença vale 0 se iguais e 1 se diferentes.

Pesos do M2. Os grupos de atributos são Demográfico (DM), Socioeconômico (SE) e Acadêmico (AC), com pesos $w_{DM} = 1$, $w_{SE} = 2$ e $w_{AC} = 3$ (17%, 33% e 50%, a mesma escala de Porto, 2022). A ordem AC > SE > DM segue a importância dos grupos para a evasão na literatura: na mesma base, a AUC média dos classificadores cai de 0,935 para 0,811 sem os atributos acadêmicos, para 0,922 sem os socioeconômicos e para 0,934 sem os demográficos (Kim et al., 2023); em outra população, média de notas, condição socioeconômica e taxa de aprovação são as variáveis mais importantes (Jiménez-Macías et al., 2023). Os pesos foram definidos *a priori*, a partir de estudos externos, e não a partir do *Target* da base, para não tornar circular o teste da H1.

Dicionário de dados. A Tabela 3 resume os 30 atributos usados (todos aplicados aos nós) e os elementos da aresta; o dicionário completo, com valores originais, número de classes e dominância, está no repositório (`dicionario_dados.csv`). O *Target* é atributo do nó usado **apenas como rótulo** na interpretação, nunca no cálculo de R_{xy}.

Tabela 3: Dicionário de dados: atributos dos nós usados na similaridade (classes após o pré-processamento) e definição das arestas.

Grupo (peso)	Atributos	Tipo
DM (1)	estado civil, turno, deslocado, gênero, idade no ingresso	nominal, binário, ordinal (8 classes)
SE (2)	qualificação e ocupação da mãe e do pai, devedor, mensalidade em dia, bolsista	nominal, binário
AC (3)	modo e ordem de candidatura, curso, qualificação prévia e sua nota, nota de admissão; por semestre (1º e 2º): UC creditadas, inscritas, avaliadas, aprovadas, sem avaliação e nota média	nominal, ordinal (até 10 classes)
Nó	`id`: identificador do estudante (0 a 4.423)	inteiro
Rótulo do nó	*Target*: Dropout, Enrolled, Graduate; comunidade	nominal (fora de R_{xy})
Aresta	origem e destino (`id`); relação simétrica; peso = R_{xy}, mín. 0,35 e máx. 1,00 na *baseline* (mediana 0,37); significado: "perfis semelhantes"	real [0, 1]

3.4 Pré-processamento e qualidade

A Tabela 4 resume a verificação de qualidade. A base não tem valores ausentes, registros duplicados nem perfis idênticos (verificado em código, não apenas pela documentação da fonte). A análise exploratória (histogramas, *boxplots* por *Target* e correlação de Spearman, no repositório) mostrou forte redundância entre semestres (UC inscritas no 1º e 2º semestres, $\rho = 0{,}96$) e menor desempenho dos evadidos nas UC aprovadas e nas notas.

Tabela 4: Relatório de qualidade dos dados.

Problema	Qtd.	Tratamento
Ausentes / duplicados / perfis idênticos	0 / 0 / 0	Nenhum necessário
Atributos com dominância ≥ 96%	3	Removidos (necessidades especiais 98,8%, nacionalidade e internacional 97,5%)
Atributos macroeconômicos	3	Removidos (iguais na coorte)
Sem UC inscritas no 1º sem. (nota 0 estrutural)	180 (4,1%)	Mantidos; classe própria na discretização
Outliers de idade (IQR)	441 (10,0%)	Discretização por quantis
Registros com categoria nominal rara (< 2%)	1.125 (25,4%)	Categoria agregada "outros"
Enrolled (desfecho em aberto)	794 (17,9%)	Mantido e analisado à parte

A Tabela 5 traz medidas descritivas de atributos representativos, e a Figura 2 compara suas distribuições por *Target*. A idade é assimétrica (mediana 20, máximo 70), e os evadidos têm menos UC aprovadas e notas menores no 2º semestre, muitas vezes iguais a zero.

Tabela 5: Medidas descritivas de atributos numéricos selecionados (antes da discretização).

Atributo	Mín.	Q1	Mediana	Q3	Máx.	Média	*Outliers*
Idade no ingresso	17	19	20	25	70	23,3	441
Nota de admissão	95,0	117,9	126,1	134,8	190,0	127,0	86
UC aprovadas (1º sem.)	0	3	5	6	26	4,7	180
Nota média (2º sem.)	0,0	10,8	12,2	13,3	18,6	10,2	877

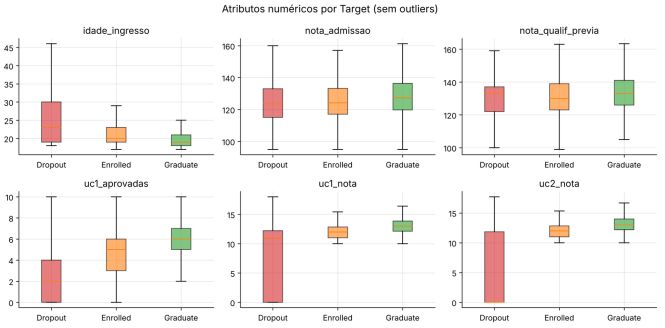


Figura 2: Distribuição de atributos numéricos por *Target* (sem *outliers*).

Seleção e transformação. Seguindo Porto (2022), atributos com dominância ≥ 96% foram removidos por não discriminarem os estudantes, assim como os macroeconômicos, restando 30 atributos (DM 5, SE 7, AC 18). Atributos numéricos com mais de 10 valores foram discretizados em 10 classes por quantis; quando mais de 50% dos registros estão no valor mínimo (ex.: UC creditadas), o mínimo recebe classe própria e o restante é dividido por quantis, evitando colapsar o atributo em uma única classe. Categorias nominais com frequência inferior a 2% foram agregadas em "outros".

***Self-loops*, multiarestas e isolados.** Somente pares $x < y$ são considerados, o que elimina *self-loops* e multiarestas por construção. Nós isolados resultam apenas de limiares altos e

são reportados para cada W (Figura 3). A consistência das relações foi verificada pela distribuição dos pesos: as similaridades médias são 0,41 (M1), 0,23 (M2) e 0,43 (M3), sem valores negativos ou fora de $[0, 1]$. Na *baseline*, os pesos são concentrados logo acima do limiar (mediana 0,37), e só pares de perfis quase idênticos se aproximam de 1.

3.5 Rede *baseline* e análise exploratória

Varredura do limiar e seleção. Para cada modelo, W variou de 0% a 90% em passos de 5%, e as comunidades foram detectadas com Fast Greedy, Louvain e Walktrap, como em Porto (2022). Redes quase completas (até 9,8 milhões de arestas) não têm estrutura de comunidade interpretável e tornam alguns algoritmos inviáveis; por isso cada algoritmo foi aplicado apenas abaixo de um limite de arestas (Louvain 6 milhões; Fast Greedy 2,5 milhões; Walktrap 600 mil). A Figura 3 mostra que o M2 é o modelo mais sensível a W: a rede passa de conexa a fragmentada entre 35% e 45%.

A rede *baseline* foi escolhida pelos critérios de Porto (2022), em ordem de prioridade: 2 a 5 comunidades; menor comunidade com ao menos 5% dos nós; maior modularidade; menos arestas entre comunidades; e maior W. Das 10 redes que atenderam aos dois primeiros critérios, a melhor de cada modelo está na Tabela 6. A escolhida é a do **M2, com** $W = 35\%$ **e Fast Greedy**, que tem modularidade bem superior às dos demais modelos e 12,5% das arestas entre comunidades.

Tabela 6: Melhor rede de cada modelo segundo os critérios de seleção.

Modelo	Algoritmo	W	L	#C	Q	#AG
M2	**Fast Greedy**	**35%**	**178.048**	**4**	**0,577**	**22.252**
M1	Louvain	50%	2.166.128	4	0,340	676.250
M3	Louvain	50%	1.797.150	4	0,220	957.601

Métricas globais. A Tabela 7 caracteriza a *baseline*. A rede é conexa (sem nós isolados), esparsa (densidade 1,8%) e de caminhos curtos (diâmetro 5). O agrupamento médio (0,30) é 16 vezes a densidade, valor esperado em uma rede aleatória, e a assortatividade de grau é fortemente positiva (0,52): estudantes de perfil "comum", com muitos semelhantes, ligam-se entre si. A distribuição de graus (Figura 4) é mais larga que a de Poisson ($\kappa = 129$ contra $\langle k \rangle \approx 80$), mas não segue lei de potência.

Tabela 7: Métricas globais da rede *baseline*.

Métrica	Valor	Métrica	Valor
Ordem N	4.424	Componentes / GCC	1 / 100%
Tamanho L	178.048	Caminho médio $\langle d \rangle$	2,94
Densidade	0,018	Diâmetro	5
$\langle k \rangle$ (mín.; máx.)	80,5 (3; 349)	Agrupamento médio	0,298
$\kappa = \langle k^2 \rangle / \langle k \rangle$	129,4	Transitividade	0,402
Nós isolados	0	Assortatividade de grau	0,518

Centralidades. Distâncias e intermediação foram calculadas sem pesos (número de saltos), pois o peso representa similaridade, e não custo. O grau correlaciona-se fortemente com a proximidade (Spearman 0,81) e moderadamente com a intermediação (0,56). Os 10 nós de maior grau pertencem todos à mesma comunidade (C3), e 9 deles são evadidos: são perfis muito representados na base. Já os 10 de maior intermediação são majoritariamente formados (7 de 10), distribuídos em três comunidades: são perfis intermediários que ligam grupos distintos.

Visualização e comunidades. A Figura 5 mostra a rede completa (layout Fruchterman–Reingold), colorida por comunidade e por *Target*, e a Figura 6 mostra a visão mesoscópica das quatro comunidades. A evasão concentra-se visualmente em uma região da rede. A Tabela 8 descreve as comunidades: **C3** reúne estudantes mais velhos (30 anos em média), com 25% de devedores, 33% com mensalidade atrasada, 32% no turno noturno e poucos bolsistas, perfil compatível com o estudante não tradicional de Bean & Metzner (1985), e concentra 59% de evadidos; **C1** reúne jovens com baixo desempenho no 1º semestre; **C4** reúne a maior fração de bolsistas e o melhor desempenho, com 7% de evasão.

Tabela 8: Perfil das comunidades (médias e percentuais).

	C1	C2	C3	C4
Estudantes	810	1.593	1.416	605
Dropout / Enrolled / Graduate (%)	33 / 26 / 40	17 / 20 / 63	**59** / 13 / 28	7 / 12 / 81
Lift de evasão (vs. 32,1%)	1,04	0,53	**1,83**	0,23
Idade média	19,8	20,1	30,3	19,9
UC aprovadas 1º sem.	2,6	5,3	4,5	6,7
Devedor / mensalidade em dia (%)	6 / 98	6 / 97	25 / 67	1 / 99
Bolsista / noturno (%)	19 / 0	34 / 2	10 / 32	43 / 0

Teste da H1. Os três critérios foram atendidos (Tabela 9): a modularidade (Louvain, sem pesos) é muito maior que a de 30 redes religadas preservando os graus; o *Target* é assortativo; e a comunidade C3 tem 1,83 vezes a fração global de evadidos, com associação significativa entre comunidade e *Target*.

Tabela 9: Testes da hipótese H1.

Critério	Resultado	Atendido
(a) Q vs. modelo nulo	0,668 vs. 0,088 ± 0,001 ($z \approx 476$)	Sim
(b) Assortatividade do *Target*	$r = 0{,}417$ (nulo 0,000; $p = 0{,}001$)	Sim
(c) Concentração de evasão	*lift* 1,83 (C3); $\chi^2 = 925$, $p < 10^{-190}$, V = 0,32	Sim

Parecer de viabilidade. Adequado com ressalvas. Os dados permitem construir uma rede conexa, esparsa e com comunidades interpretáveis, que responde à RQ1. As ressalvas são: a rede é uma aproximação por perfis, sem interação real; os resultados dependem do modelo de similaridade, dos pesos e de W; e a base é de uma única instituição.

Compatibilidade com a Fase 1. A Tabela 10 responde às questões de verificação da AT2.

Tabela 10: Verificação dos dados frente à definição do problema.

Questão	Resposta
Os nós estão nos dados?	Sim: um registro por estudante (4.424).
As relações são identificáveis?	Não diretamente; são derivadas da similaridade de atributos.
É possível construir a rede?	Sim, com os modelos M1–M3 e o limiar W.
Há atributos relevantes?	Sim: 30 atributos após a seleção, e o *Target* como rótulo.
O recorte é suficiente?	Sim para análise descritiva (10 anos, 17 cursos); uma instituição.
É preciso reformular o problema?	Parcialmente: sem fins preditivos e sem interação real.
A rede é direta ou aproximação?	Aproximação por perfis, não rede de contatos.

Ajustes na Fase 1 e padrões a investigar. A verificação dos dados levou a: (*i*) retirar o termo "previsão" do título e dos objetivos, pois a rede é descritiva e os atributos de semestre antecipam o desfecho; (*ii*) declarar a rede como aproximação por perfis; e (*iii*) formular a RQ1 sobre comunidades e concentração de evasão, que os dados permitem testar. Os padrões registrados para as etapas seguintes foram: comunidades bem definidas; conectividade maior entre perfis frequentes (assortatividade de grau); concentração de evadidos em uma região

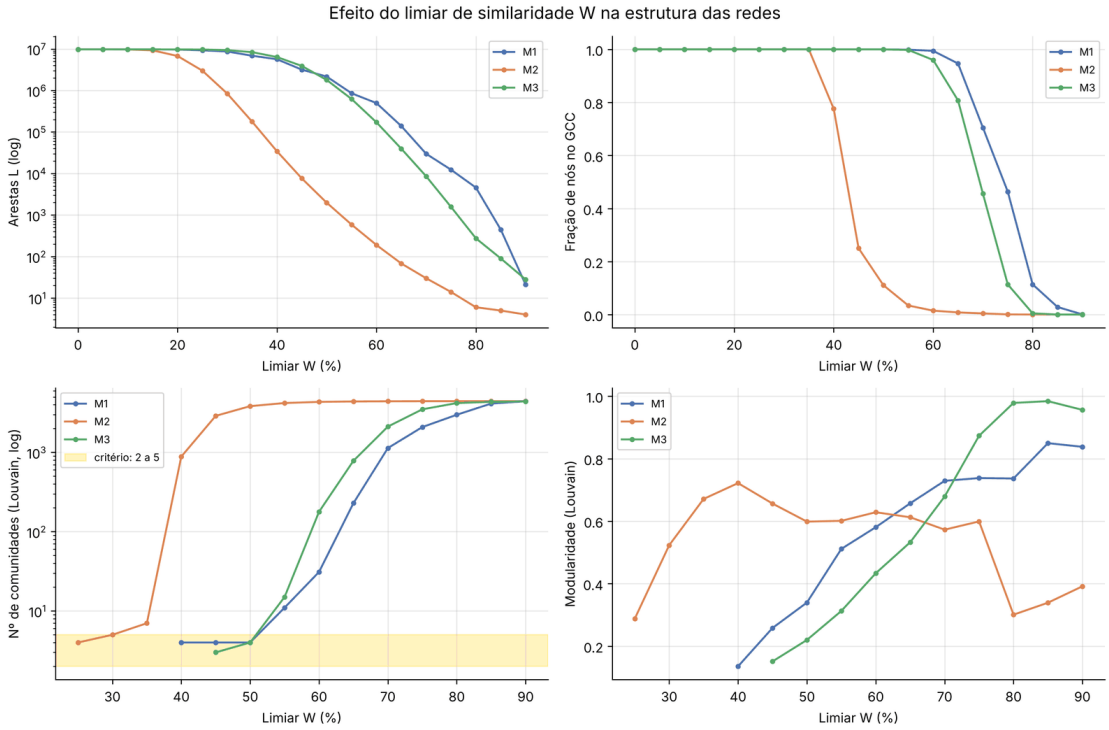


Figura 3: Efeito do limiar W no número de arestas, na fração de nós no GCC, no número de comunidades (Louvain; faixa amarela: critério de 2 a 5) e na modularidade.

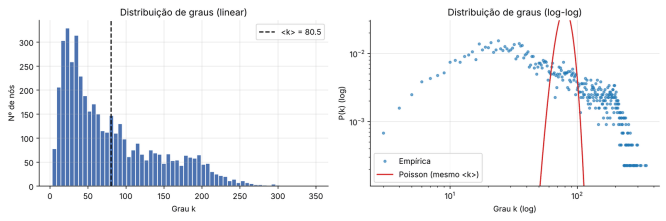


Figura 4: Distribuição de graus em escala linear e log-log, com a Poisson de mesmo $\langle k \rangle$.

da rede; e poucos perfis intermediários ligando as comunidades.

3.6 Modelos de referência

Seleção e geração. A *baseline* foi comparada a três modelos: **ER**, como modelo nulo de ligações ao acaso; **WS**, porque redes construídas por proximidade de atributos tendem a ser de mundo pequeno, com agrupamento alto; e **BA**, para testar se a heterogeneidade de graus decorre de ligação preferencial. Todos têm $N = 4.424$ e L próximo de 178.048: ER $G(N, L)$ reproduz L exatamente; WS usa anel com $K = 80$ vizinhos (L com desvio de $-0{,}6\%$); BA usa $m = 40$ ($-1{,}1\%$). A probabilidade de religação do WS foi **calibrada numericamente** ($p = 0{,}144$) para reproduzir o agrupamento médio empírico. Foram geradas **30 réplicas** por modelo, com sementes fixas (42 a 71). Caminho médio e diâmetro foram estimados por busca em largura a partir de 400 nós sorteados, igualmente na rede empírica e nos modelos.

Comparação. A Tabela 11 compara as métricas (média ± desvio-padrão). A aderência foi medida pelo erro relativo e pelo *z-score* de cada métrica, e resumida pela média do erro relativo nas métricas não fixadas pela calibração (grau máximo, heterogeneidade, agrupamento, transitividade, caminho médio, diâmetro e assortatividade).

Tabela 11: Rede empírica vs. modelos (30 réplicas; média ± desvio).

Métrica	Empírica	ER	WS	BA
$\langle k \rangle$	80,5	80,5 ± 0,0	80,0 ± 0,0	79,6 ± 0,0
$k_{\max}$	349	115 ± 3	97 ± 1	643 ± 26
κ	129,4	81,5 ± 0,0	80,3 ± 0,0	142,3 ± 0,7
Agrupamento médio	0,298	0,018 ± 0,000	0,298 ± 0,001	0,057 ± 0,001
Transitividade	0,402	0,018 ± 0,000	0,297 ± 0,001	0,059 ± 0,000
Caminho médio	2,95	2,21 ± 0,00	2,47 ± 0,00	2,20 ± 0,00
Diâmetro	5	3	3	3
GCC (% dos nós)	100	100	100	100
Assortatividade	0,518	0,000 ± 0,003	0,000 ± 0,002	0,011 ± 0,002
Erro relativo médio	–	65,5%	**41,8%**	60,5%

Aderência e discrepâncias. O **WS é o modelo mais aderente** (Tabela 11), mas reproduz o agrupamento por calibração. O caminho médio do WS difere em 16,4% do empírico, pouco acima do critério de ±15% definido na Fase 1; por isso, a RQ2 é considerada **parcialmente atendida**. A rede é de **mundo pequeno**: $\sigma = (0{,}298/0{,}018)/(2{,}95/2{,}21) \approx 12{,}4 > 1$, o que **confirma a H2**. Duas propriedades não são reproduzidas por nenhum modelo (Figuras 7 e 8): (*i*) a **assortatividade de grau** (0,52 contra cerca de 0 nos três modelos), consequência da transitividade da similaridade, em que perfis comuns são semelhantes entre si; e (*ii*) a **forma da distribuição de graus**: o ER e o WS são homogêneos demais ($k_{\max} \approx 100$), e o BA concentra demais ($k_{\max} = 643$), embora seja o único a aproximar κ. O caminho médio e o diâmetro maiores na rede empírica refletem sua estrutura em comunidades, ausente nos modelos.

Sensibilidade dos parâmetros. No WS, o agrupamento cai de 0,74 ($p \to 0$) para 0,40 em $p = 0{,}1$ e 0,20 em $p = 0{,}2$, enquanto o caminho médio cai rapidamente, de 4,8 ($p = 0{,}0005$)

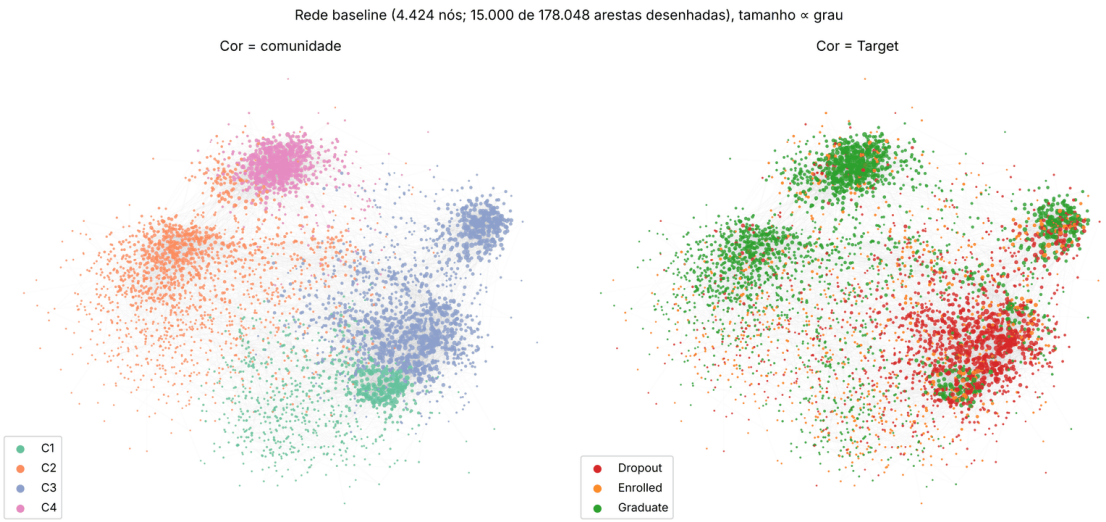


Figura 5: Rede *baseline* (4.424 nós; 15 mil arestas sorteadas desenhadas para legibilidade; tamanho ∝ grau). Esquerda: comunidades. Direita: *Target*.

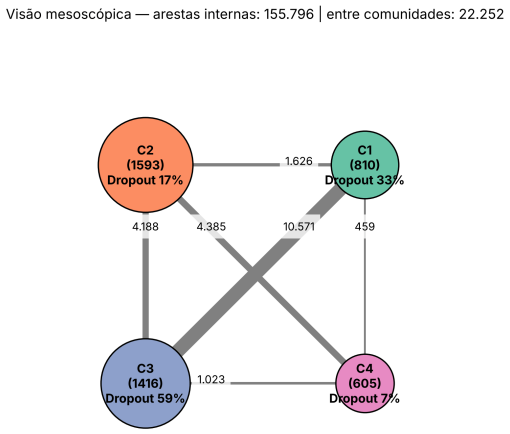


Figura 6: Visão mesoscópica: área ∝ tamanho da comunidade; espessura ∝ arestas entre comunidades.

para 3,0 ($p = 0{,}01$); o p calibrado (0,144) está no regime de mundo pequeno. No BA, variar m de 20 a 60 aumenta o agrupamento só de 0,03 para 0,08 e mantém a assortatividade próxima de zero, ou seja, nenhum m aproxima a rede empírica (Figura 9).

Limitações e causalidade. Os modelos clássicos descrevem mecanismos de formação de arestas (acaso, religação, ligação preferencial) que não existem na rede estudada, cujas arestas derivam de uma regra de similaridade. A aderência ao WS é, portanto, uma **semelhança estrutural**, não uma explicação causal: não indica que estudantes se "conectem" por um processo de mundo pequeno, nem identifica causas da evasão. Um grafo geométrico aleatório (Dall & Christensen, 2002) seria um modelo de referência mais próximo do mecanismo e fica como trabalho futuro.

3.7 Robustez da rede

Definições. Na rede de perfis, **funcionamento** significa a coesão da população: perfis diferentes permanecem ligados por cadeias de perfis semelhantes. A **unidade de perturbação** é o nó, pois remover um estudante corresponde a ele deixar a instituição. A propriedade preservada é a fração S de nós no GCC. O **critério de falha** é a fragmentação: o GCC passa a conter menos da metade dos nós restantes, $S_{rel} = S/(1-f) < 0{,}5$, em que f é a fração removida. O critério absoluto $S < 10\%$ de N seria trivial nesta rede, pois com $f \geq 0{,}9$ restam no máximo 10% dos nós mesmo sem fragmentação.

Cenários. f variou de 0 a 0,95 em passos de 0,05: (A) **falhas aleatórias**, com 30 réplicas e IC de 95%; (B) **ataque por grau** e (C) **ataque por intermediação**, ambos recalculando a centralidade a cada passo (estratégia adaptativa); e (D) **remoção dos evadidos**, em ordem aleatória (30 réplicas), comparada ao cenário A com a mesma fração. Os cenários diferem em plausibilidade: a saída real de estudantes corresponde ao cenário D (evasão) ou a saídas dispersas (A), enquanto B e C são cenários extremos, que medem o quanto a coesão depende dos perfis mais centrais. As métricas monitoradas a cada passo são S, S_{rel}, número de componentes, caminho médio no GCC e fração do peso total remanescente, esta última como adaptação à rede ponderada. Falhas em cascata não foram simuladas: a saída de um estudante não altera a similaridade entre os demais, pois a rede é estática e derivada de atributos.

Resultados. A Figura 10 e a Tabela 12 resumem as simulações. Sob **falhas aleatórias** a rede não se fragmenta até $f = 0{,}95$, o que concorda com o critério de Molloy & Reed (1995): com $\kappa = 129$, o limiar teórico é $f_c = 1 - 1/(\kappa - 1) \approx 0{,}99$. O **ataque por grau** fragmenta a rede em $f_c = 0{,}82$, de forma abrupta, e é o que mais reduz o peso remanescente, pois remove primeiro os perfis mais conectados. O **ataque por intermediação** é o mais destrutivo ($f_c = 0{,}60$): ao remover os perfis-ponte, a rede se divide nas comunidades. Logo, $f_c^{\text{ataque}} < f_c^{\text{aleatória}}$ nos dois ataques, o que **confirma a H3**. No cenário D, remover os 1.421 evadidos (32% dos nós) deixa $S = 0{,}68$, praticamente o mesmo que remover 30% dos nós ao acaso ($S = 0{,}70$): os evadidos estão concentrados na C3 e **não**

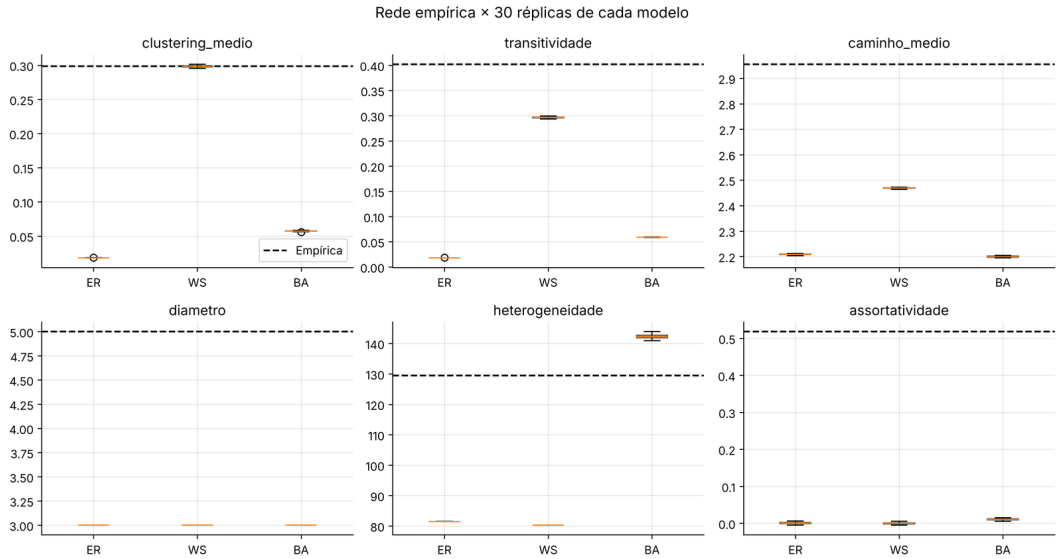


Figura 7: Variabilidade das 30 réplicas de cada modelo; a linha tracejada é o valor da rede empírica.

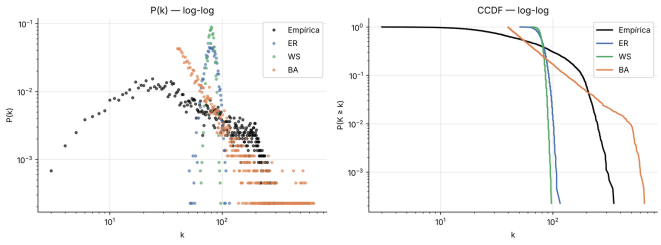


Figura 8: $P(k)$ e distribuição acumulada complementar (log-log): rede empírica e modelos.

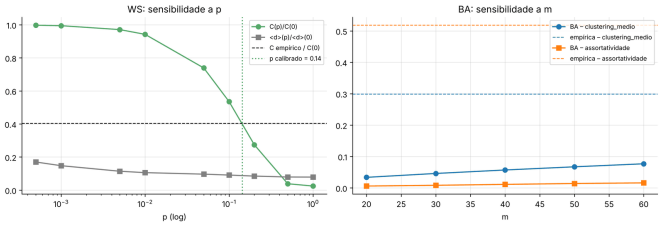


Figura 9: Sensibilidade aos parâmetros: probabilidade de religação p no WS (esquerda) e ligações por nó m no BA (direita); linhas tracejadas: valores empíricos.

são pontes entre perfis.

Tabela 12: Limiar crítico f_c ($S_{rel} < 0{,}5$) por rede e cenário.

Rede	A – Aleatória	B – Grau	C – Intermediação
Empírica	> 0,95	0,82	**0,60**
ER	> 0,95	0,92	–
WS	> 0,95	0,92	–
BA	> 0,95	0,82	–

Elementos críticos. A Tabela 13 lista os nós mais críticos. Os de maior grau são evadidos da C3, perfis muito frequentes na base; os 5% de maior grau concentram-se na C3 (136 de 221) e na C4 (68). Os de maior intermediação são, em maioria, formados de comunidades distintas: entre os 5% de maior intermediação, 112 de 221 são formados e todas as comunidades estão representadas. Esses perfis intermediários sustentam a coesão da rede.

Tabela 13: Nós críticos por grau e por intermediação.

Métrica	Nó	Valor	Com.	Target	Papel no domínio
Grau	951	349	C3	Dropout	Perfil típico de risco, muito frequente
	2748	342	C3	Dropout	
	3682	317	C3	Dropout	
Intermediação	4241	0,0065	C4	Dropout	Perfil-ponte entre comunidades
	1909	0,0031	C2	Graduate	
	3449	0,0030	C4	Graduate	

Articulação com os modelos. O mesmo protocolo aplicado aos modelos da Subseção 3.6 (Tabela 12) mostra que, sob ataque por grau, a rede empírica se comporta como o BA ($f_c = 0{,}82$), mais vulnerável que ER e WS ($\approx 0{,}92$), por causa de sua maior heterogeneidade de graus. Sua maior vulnerabilidade, porém, é ao ataque por intermediação, efeito da estrutura em comunidades que nenhum dos modelos possui.

Recomendações. (*i*) Priorizar a comunidade C3 em ações financeiras (renegociação de dívidas e bolsas) e de flexibilidade de horário, compatíveis com seu perfil de estudante mais velho, devedor e noturno; (*ii*) acompanhar a C1 com apoio pedagógico já no 1º semestre; e (*iii*) usar os perfis de alta intermediação para desenhar ações de integração entre grupos, já que sustentam a coesão da população.

Limitações. As simulações são estáticas: a remoção de nós não altera os atributos nem a similaridade dos demais, e a ordem real de saída dos estudantes não é considerada. O critério de falha ($S_{rel} < 0{,}5$) é uma escolha de modelagem, e os ataques nos modelos sintéticos usaram uma réplica por modelo.

4 Considerações Parciais

A Tabela 14 resume a verificação das hipóteses. A rede de similaridade construída com o método de Porto (2022) mostrou-se adequada ao problema: é conexa, esparsa, de mundo pequeno e organizada em quatro comunidades interpretáveis, uma das quais concentra a evasão. A estrutura que distingue a rede dos modelos clássicos (assortatividade de grau e comunidades) é

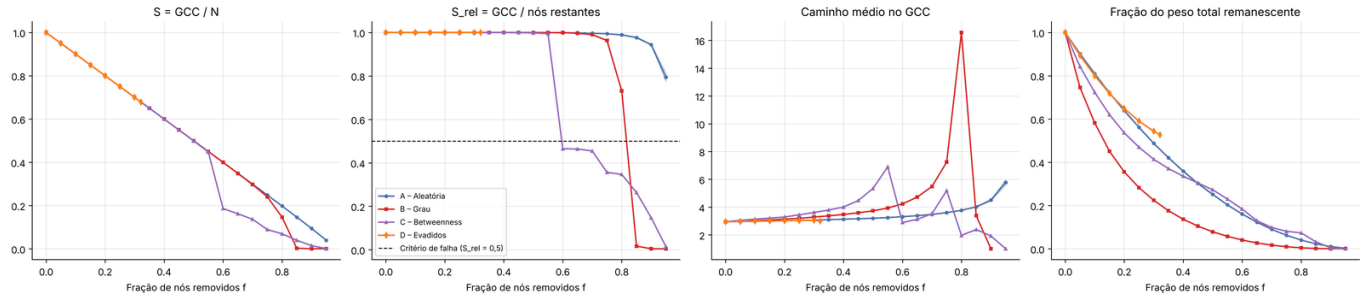


Figura 10: Curvas de degradação nos quatro cenários: S, S_{rel} (linha tracejada: critério de falha), caminho médio no GCC e peso remanescente. Bandas: IC de 95% (30 réplicas).

também a que determina sua vulnerabilidade, maior a ataques por intermediação.

Tabela 14: Síntese das questões e hipóteses.

RQ / H	Evidência	Situação
RQ1 / H1	Q muito acima do nulo; *Target* assortativo; C3 com 59% de evasão	Confirmada
RQ2 / H2	WS mais aderente; $\sigma \approx 12{,}4$; caminho médio com erro de 16,4%	H2 confirmada; RQ2 parcial
RQ3 / H3	f_c: aleatória > 0,95; grau 0,82; intermediação 0,60	Confirmada

Os próximos passos são: testar a estabilidade das comunidades frente aos pesos do M2 e ao limiar W; comparar a rede com um grafo geométrico aleatório; e aprofundar a interpretação das comunidades C1 e C3 à luz dos modelos de Tinto (1975) e Bean & Metzner (1985).

Referências

Albert, R., Jeong, H., & Barabási, A.-L. (2000). Error and attack tolerance of complex networks. *Nature*, 406, 378–382.

Almeida, P. G., Silva, G. A. L., Santos, V., Moreira, G. J. P., Silva, P. H. L., & Luz, E. J. d. S. (2025). Deep learning for school dropout detection: A comparison of tabular and graph-based models for predicting at-risk students. Em *Anais do XVII Congresso Brasileiro de Inteligência Computacional (CBIC)* Belo Horizonte, MG.

Barabási, A.-L. (2016). *Network Science*. Cambridge: Cambridge University Press.

Barabási, A.-L. & Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509–512.

Bean, J. P. & Metzner, B. S. (1985). A conceptual model of nontraditional undergraduate student attrition. *Review of Educational Research*, 55(4), 485–540.

Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008.

Clauset, A., Newman, M. E. J., & Moore, C. (2004). Finding community structure in very large networks. *Physical Review E*, 70(6), 066111.

Colpo, M. P., Primo, T. T., Aguiar, M. S. d., & Cechinel, C. (2024). Educational data mining for dropout prediction: Trends, opportunities, and challenges. *Revista Brasileira de Informática na Educação*, 32, 220–256.

Csárdi, G. & Nepusz, T. (2006). The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695.

Dall, J. & Christensen, M. (2002). Random geometric graphs. *Physical Review E*, 66(1), 016121.

Erdős, P. & Rényi, A. (1959). On random graphs I. *Publicationes Mathematicae Debrecen*, 6, 290–297.

Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Waltham: Morgan Kaufmann, 3 edição.

Humphries, M. D. & Gurney, K. (2008). Network 'small-world-ness': A quantitative method for determining canonical network equivalence. *PLoS ONE*, 3(4), e0002002.

INEP (2016). Indicadores de fluxo da educação superior: trajetória dos ingressantes de 2010 (censo da educação superior). Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, Brasília.

Jiménez-Macías, A., Muñoz-Merino, P. J., Ortiz-Rojas, M., Delgado Kloos, C., & Moreno-Marcos, P. M. (2023). Analyzing feature importance for a predictive undergraduate student dropout model. *Computer Science and Information Systems*, 20(1), 175–194.

Kim, S., Yoo, E., & Kim, S. (2023). Why do students drop out? University dropout prediction and associated factor analysis using machine learning techniques. arXiv:2310.10987.

Menezes, V. S. d. A. (2012). *Análise de Redes Sociais Científicas*. PhD thesis, Universidade Federal do Rio de Janeiro.

Molloy, M. & Reed, B. (1995). A critical point for random graphs with a given degree sequence. *Random Structures & Algorithms*, 6(2–3), 161–180.

Newman, M. E. J. (2002). Assortative mixing in networks. *Physical Review Letters*, 89(20), 208701.

Newman, M. E. J. (2006). Modularity and community structure in networks. *Proceedings of the National Academy of Sciences*, 103(23), 8577–8582.

Newman, M. E. J. & Girvan, M. (2004). Finding and evaluating community structure in networks. *Physical Review E*, 69(2), 026113.

Pons, P. & Latapy, M. (2006). Computing communities in large networks using random walks. *Journal of Graph Algorithms and Applications*, 10(2), 191–218.

Porto, R. d. A. (2022). Detecção de comunidades para identificação de grupos de solicitantes de auxílio estudantil. Trabalho de Conclusão de Curso (Sistemas de Informação), Universidade Federal de Itajubá, Itajubá.

Porto, R. d. A. & Frinhani, R. d. M. D. (2021). Descoberta de conhecimento no apoio a tomada de decisão na gestão acadêmica em uma instituição federal de ensino superior. ResearchGate. Disponível em: www.researchgate.net/publication/356099663.

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. *Data*, 7(11), 146.

Tinto, V. (1975). Dropout from higher education: A theoretical synthesis of recent research. *Review of Educational Research*, 45(1), 89–125.

Tontini, G. & Walter, S. A. (2014). Pode-se identificar a propensão e reduzir a evasão de alunos? ações estratégicas e resultados táticos para instituições de ensino superior. *Avaliação: Revista da Avaliação da Educação Superior*, 19(1), 89–110.

Watts, D. J. & Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393, 440–442.

