Projeto XMCO09: o que fizemos, como e por quê

Guia do grupo (Bianca, Filipe e Laura) sobre o artigo parcial (AT1–AT4), para a apresentação e o artigo final.

1. A ideia em uma frase

A base de **Realinho et al. (2022)** tem 4.424 estudantes com atributos, mas **não tem relação entre eles**. Por isso **criamos a rede**: cada estudante é um nó, e dois estudantes são ligados quando seus **perfis são parecidos**. Depois verificamos se a **evasão se concentra em grupos** dessa rede. O método de construção veio do **TCC do Rodrigo Porto (2022)**, indicado pelo professor na consultoria.

Dados = Realinho (o que analisamos) · **Método** = Porto (como montamos a rede) · **Nossa contribuição** = aplicar o método do Porto à evasão e testá-lo com modelos nulos, modelos clássicos e robustez.

AT1 problema, perguntas (RQ) e hipóteses (H) → **AT2** dados → rede de similaridade → comunidades → **AT3** comparar com redes teóricas (ER, WS, BA) → **AT4** remover nós e ver quando a rede quebra

2. O que fizemos em cada atividade

AT1: o problema. Perguntamos três coisas. **RQ1:** existem grupos, e os evadidos se concentram neles? **RQ2:** com qual rede teórica a nossa se parece? **RQ3:** a rede quebra mais com saídas ao acaso ou com a retirada dos nós mais importantes? Cada pergunta ganhou uma hipótese (H1, H2, H3) com um **teste numérico definido antes** de ver o resultado.

AT2: dos dados à rede.

1. **Limpeza.** A base não tinha ausentes nem duplicados. Removemos 3 atributos quase constantes (mais de 96% dos alunos com o mesmo valor, regra do Porto) e 3 macroeconômicos, que são iguais para todos do mesmo ano. Sobraram **30 atributos**, divididos em Demográfico (DM), Socioeconômico (SE) e Acadêmico (AC).
2. **Similaridade.** Testamos os 3 modelos do Porto. **M1** conta quantos atributos são iguais. **M2** faz a contagem por grupo, com pesos AC = 3, SE = 2 e DM = 1. **M3** usa uma distância normalizada.
3. **Limiar W.** Só vira aresta o par com similaridade $\geq W$. Variamos W de 0% a 90% e rodamos 3 algoritmos de comunidades (Fast Greedy, Louvain e Walktrap).
4. **Escolha** pelos critérios do Porto: 2 a 5 comunidades, nenhuma com menos de 5% dos alunos, maior modularidade. Venceu **M2, $W = 35\%$, Fast Greedy**.

AT3: modelos teóricos. Geramos 30 redes de cada modelo (ER = aleatória, WS = mundo pequeno, BA = com *hubs*), todas com o mesmo número de nós e arestas que a nossa, e comparamos as métricas.

AT4: robustez. Removemos nós de quatro formas: ao acaso; pelos de maior grau; pelos de maior intermediação (os "pontes"); e só os evadidos. Medimos quando a rede se fragmenta, isto é, quando o maior componente passa a ter menos da metade dos nós restantes.

3. Números para saber de cor

Rede escolhida	4.424 nós, 178.048 arestas, conexa, densidade 1,8%, grau médio 80
Comunidades	4, com modularidade 0,58. **C3: 59% de evasão** (base: 32%). C3 = alunos mais velhos (30 anos), 25% devedores, 32% noturno. **C4: 7%** (43% bolsistas)
H1 (grupos)	**Confirmada**: modularidade muito acima de redes aleatórias; o *Target* é assortativo; C3 tem 1,83× a evasão média
H2 (mundo pequeno)	**Confirmada**: $\sigma = 12{,}4 > 1$. O WS é o modelo mais próximo, mas a RQ2 é **parcial**: o erro no caminho médio foi de 16%, acima do limite de 15%
Discrepância	Nenhum modelo reproduz a **assortatividade** (0,52; nossos "perfis comuns" se ligam entre si) nem as comunidades
H3 (ataques)	**Confirmada**: ao acaso, a rede não quebra até 95%; por grau, quebra em 82%; por intermediação, em **60%**
Evadidos	Removê-los equivale a remover alunos ao acaso: **eles não são pontes**, estão concentrados na C3

4. Perguntas que o professor pode fazer

- **"Se os alunos não interagem, o que é a aresta?"** Similaridade de perfil. A rede é uma **aproximação**, e isso está declarado no artigo.
- **"Por que o *Target* não entrou na similaridade?"** Se entrasse, os evadidos se agrupariam por construção, e a H1 ficaria **circular**. Ele só é usado para interpretar a rede.
- **"De onde vieram os pesos 1, 2 e 3?"** Da literatura: Kim et al. (2023), **na mesma base**, mostram que o grupo acadêmico é o que mais pesa na previsão de evasão, seguido do socioeconômico. Jiménez-Macías et al. (2023) confirmam em outra universidade. A escala é a mesma do Porto.
- **"Por que $W = 35\%$?"** Pelos critérios do Porto. Abaixo disso a rede é densa demais (milhões de arestas); acima de 40%, centenas de alunos ficam isolados.
- **"A rede segue o WS?"** Ela se **parece** com o WS (mundo pequeno), mas isso não é causa: as arestas vêm de uma regra de similaridade, não de religação.
- **"Por que não usaram o critério de falha de 10%?"** Removendo 90% dos nós, sobram no máximo 10% mesmo sem nenhuma quebra. Por isso medimos a fragmentação em relação aos nós restantes.

5. Erros e acertos (o que aprendemos)

O que deu errado	Como corrigimos
A primeira versão da rede (rascunho) não funcionou, segundo a consultoria.	Seguimos o método do TCC do Porto, indicado pelo professor.
O rascunho prometia "previsão", "falhas em cascata" e "ataques a clusters de risco".	Removemos: o trabalho é descritivo, a cascata não se aplica e os ataques são por grau e intermediação.
Chegamos a pensar em definir os pesos pelo *Target*.	Seria circular; os pesos passaram a vir da literatura.
Calibrar o WS por fórmula deu p errado (0,26).	Calibração numérica: $p = 0{,}144$, que reproduz o agrupamento.
O critério "maior componente $< 10\%$" era trivial.	Trocado por "menos da metade dos nós restantes".
Python 3.15 não instalava as bibliotecas.	Usar **Python 3.12**, como está no README.

Acertos que valem manter: hipóteses com teste numérico definido antes; comparação com modelos nulos; sementes fixas (`SEED = 42`); cada célula do código marcada com o item do formulário que atende; resultados "parciais" reportados com honestidade.

6. Para o artigo final (máx. 12 páginas, apresentação de 15–20 min)

1. **Reorganizar o texto:** levar os resultados da Metodologia para as seções **Resultados** e **Conclusões** e enxugar para caber nas 12 páginas.
2. **Estabilidade das comunidades:** verificar se as 4 comunidades se mantêm com W de 30% a 40% e com pesos iguais (1/1/1). É a pergunta mais provável da banca.
3. **Modelo de referência mais adequado:** testar um grafo geométrico aleatório, que forma arestas por proximidade, como a nossa rede.
4. **Classe *Enrolled*:** analisá-la à parte, já que o desfecho desses alunos ainda está em aberto.
5. **Ligar à teoria:** interpretar C1 e C3 com Tinto (1975) e Bean & Metzner (1985). A C3 é o "estudante não tradicional".
6. **Apresentação longa:** seguir as diretrizes de slides (uma ideia por slide, fonte em toda figura) e reaproveitar os slides atuais.

7. Onde está cada coisa

Repositório: `https://github.com/biancas2-zz/xmco09-evasao-redes`

- `evasao_redes.ipynb`: dados, construção da rede, métricas e comunidades (AT2 + H1). Rodar primeiro (cerca de 15 min).
- `modelos_robustez.ipynb`: modelos teóricos e robustez (AT3 + AT4). Rodar depois (cerca de 10 min).
- `figuras/` e `resultados/`: tudo o que aparece no artigo; `artigo/` e `slides/`: arquivos LaTeX e PDFs.